

5장 모수적 모델과 지수 패밀리

2019.08.14

신 현석

들어가며

전통적 통계학 방법론 : 저차원 모수, 확률밀도 \rightarrow 수학적 용이

$$\mathcal{F} = \{f_\mu(x); x \in \mathcal{X}, \mu \in \Omega\}$$

확률밀도함수

모수 200/하

가장 보편적 모수적 모델

지수분포 : 전통 - 컴퓨터 시대의 연결점




Figure 8.3 Three levels of statistical modeling.

5.1 일변량 패밀리 정규, 포아송, 이항, 감마, 베타

Name, Notation	Density	\mathcal{X}	Ω	Expectation, Variance
Normal $\mathcal{N}(\mu, \sigma^2)$	$\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$	\mathcal{R}^1	$\mu \in \mathcal{R}^1$ $\sigma^2 > 0$	μ σ^2
Poisson $\text{Poi}(\mu)$	$\frac{e^{-\mu}\mu^x}{x!}$	$\{0, 1, \dots\}$	$\mu > 0$	μ μ
Binomial $\text{Bi}(n, \pi)$	$\frac{n!}{x!(n-x)!} \pi^x (1-\pi)^{n-x}$	$\{0, 1, \dots, n\}$	$0 < \pi < 1$	$n\pi$ $n\pi(1-\pi)$
지수 카이제곱	$\frac{x^{\nu-1} e^{-x/\sigma}}{\sigma^\nu \Gamma(\nu)}$	$x \geq 0$	$\nu > 0$ $\sigma > 0$	$\sigma\nu$ $\sigma^2\nu$
Beta $\text{Be}(\nu_1, \nu_2)$	$\frac{\Gamma(\nu_1+\nu_2)}{\Gamma(\nu_1)\Gamma(\nu_2)} x^{\nu_1-1} (1-x)^{\nu_2-1}$	$0 \leq x \leq 1$	$\nu_1 > 0$ $\nu_2 > 0$	$\nu_1/(\nu_1 + \nu_2)$ $\frac{\nu_1\nu_2}{(\nu_1+\nu_2)^2(\nu_1+\nu_2+1)}$

이항분포: 성공확률이 p , 실패확률이 $q = 1 - p$ 인 베르누이 시행의 n 회의 독립시행에서 성공 횟수를 나타내는 이항확률변수 X 의 확률분포는

$$b(x; n, p) = \binom{n}{x} p^x q^{n-x}, \quad x = 0, 1, 2, \dots, n \text{ 으로 주어진다.}$$

포아송 분포 : 주어진 시간간격 t 동안에, 혹은 일정 영역 t 에서 발생하는 결과의 수를 나타내는

포아송 확률변수 X 의 확률분포 : $p(x; \lambda t) = \frac{e^{-\lambda t} (\lambda t)^x}{x!}, \quad x = 0, 1, 2, \dots$

여기서 λ 는 단위시간 또는 단위면적에서 발생하는 결과의 수, $e = 2.71828 \dots$

*** 이항분포와 포아송 분포

이항분포에서, $n \rightarrow \infty$, $p \rightarrow 0$, np 는 상수인 경우, 포아송 분포에 가까워짐.

n 이 크고 p 가 0에 가까운 값이면 이항분포를 포아송 분포로 근사. (p 가 1에 가까우면, 성공과 실패를 바꾸어 근사)

*** 이항분포와 포아송 분포

이항분포에서, $n \rightarrow \infty$, $p \rightarrow 0$, np 는 상수인 경우, 포아송 분포에 가까워짐.

n 이 크고 p 가 0에 가까운 값이면 이항분포를 포아송 분포로 근사. (p 가 1에 가까우면, 성공과 실패를 바꾸어 근사)

$$\text{증명) } p = \frac{\mu}{n} \text{ 이므로}$$

$$\begin{aligned} b(x; n, p) &= \binom{n}{x} p^x q^{n-x} = \frac{n!}{x!(n-x)!} p^x (1-p)^{n-x} \\ &= \frac{n(n-1)\cdots(n-x+1)}{x!} p^x (1-p)^{n-x} \\ &= \frac{n(n-1)\cdots(n-x+1)}{x!} \left(\frac{\mu}{n}\right)^x \left(1 - \frac{\mu}{n}\right)^{n-x} \\ &= 1\left(1 - \frac{1}{n}\right)\cdots\left(1 - \frac{x-1}{n}\right) \frac{\mu^x}{x!} \left(1 - \frac{\mu}{n}\right)^n \left(1 - \frac{\mu}{n}\right)^{-x} \end{aligned}$$

$n \rightarrow \infty$ 이면 (x, μ 는 상수)

$$\lim_{n \rightarrow \infty} 1\left(1 - \frac{1}{n}\right)\cdots\left(1 - \frac{x-1}{n}\right) = 1, \quad \lim_{n \rightarrow \infty} \left(1 - \frac{\mu}{n}\right)^{-x} = 1,$$

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\mu}{n}\right)^n = \lim_{n \rightarrow \infty} \left(1 + \frac{-\mu}{n}\right)^n = e^{-\mu}$$

$$(\because e = \lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^n \text{ 이므로 } \lim_{n \rightarrow \infty} \left(1 + \frac{x}{n}\right)^n = \lim_{n \rightarrow \infty} \left(\left(1 + \frac{1}{n/x}\right)^{\frac{n}{x}}\right)^x = e^x)$$



$$\text{그리므로 } b(x; n, p) \rightarrow 1 \cdot \frac{\mu^x}{x!} e^{-\mu} \cdot 1 = \frac{e^{-\mu} \mu^x}{x!} = p(x; \mu) \text{ 이다.}$$

감마분포 : 연속확률변수 X 의 확률밀도함수가

$$f(x; \alpha, \beta) = \begin{cases} \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-\frac{x}{\beta}}, & x > 0 \\ 0 & \text{그 외의 } x \end{cases}$$

$$(\alpha > 0, \beta > 0)$$

와 같이 주어질 때 X 는 모수 α, β 를 가지는 감마분포를 따른다고 한다.



(α : 모양을 결정 – shape parameter, β : 크기를 결정 – scale parameter)

* $\alpha = 1$ 인 특수한 감마분포를 지수분포라 한다.


카이제곱 분포(chi-square distribution) : $\alpha = \frac{v}{2}$ (v 는 양의 정수), $\beta = 2$ 인 경우의 감마분포

베타분포 : 확률밀도함수가

$$f(x; \alpha, \beta) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}, \quad 0 < x < 1, \quad \alpha, \beta > 0$$

$$B(\alpha, \beta) = \frac{\Gamma(\alpha)\Gamma(\beta)}{\Gamma(\alpha+\beta)}$$

인 분포를 모수가 α, β 인 베타분포라 한다.



5.2 다변량 정규분포

$$x \sim \mathcal{N}_p(\mu, \Sigma)$$

여러 변수 - 하나의 벡터

예) 신체검사 - 나이, 키, 몸무게, 혈압

예) 입시 - 시험성적, 졸업성적, 면접성적

- 각 벡터의 원소들 사이에 연관성 존재.

$$\mu = E\{x\} = (E\{x_1\}, E\{x_2\}, \dots, E\{x_p\})'$$


$$\Sigma = E\{(x - \mu)(x - \mu)'\} = (E\{(x_i - \mu_i)(x_j - \mu_j)\})$$

$$= T T'$$

$$* X \text{의 평균벡터}: \mu = (\mu_1, \mu_2, \dots, \mu_p)^t = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix},$$

$$X \text{의 공분산행렬(분산행렬)}: \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix} = [Cov(X_i, X_j)]$$

$$f_{\mu, \Sigma}(x) = \frac{(2\pi)^{-p/2}}{|\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\mu)' \Sigma^{-1} (x-\mu)}$$


상수 : $(1 \times p) \times (p \times p) \times (p \times 1) = 1 \times 1$

$$f(z) = (2\pi)^{-\frac{p}{2}} e^{-\frac{1}{2} \sum_1^p z_i^2} = (2\pi)^{-\frac{p}{2}} e^{-\frac{1}{2} z' z}$$

$$x = \mu + T z$$

[p. 57] *Formula (5.12).* From $z = T^{-1}(x - \mu)$ we have $dz/dx = T^{-1}$ and

$$f_{\mu, \Sigma}(x) = f(z)|T^{-1}| = (2\pi)^{-\frac{p}{2}} |T^{-1}| e^{-\frac{1}{2}(x-\mu)' T^{-1}' T^{-1} (x-\mu)}, \quad (5.63)$$

so (5.12) follows from $TT' = \Sigma$ and $|T| = |\Sigma|^{1/2}$.

If $p_1 = p_2 = 1$, then (5.18) reduces to

$$x_2|x_1 \sim \mathcal{N} \left(\mu_2 + \frac{\sigma_{12}}{\sigma_{11}}(x_1 - \mu_1), \sigma_{22} - \frac{\sigma_{12}^2}{\sigma_{11}} \right)$$

* $X = x$ 일 때 Y 의 조건부 평균이 x 에 대해 선형인 경우($E(Y|x) = a + bx$):

이산형인 경우 $a + bx = E(Y|x) = \sum_y y f(y|x) = \sum_y y \frac{f(x,y)}{f_X(x)}$ 이므로,

$$\sum_y y f(x,y) = (a + bx) f_X(x)$$

$$\sum_x \sum_y y f(x,y) = \sum_x (a + bx) f_X(x)$$

$$\mu_Y = a + b\mu_X \quad (1)$$

또한, $\sum_y y f(x,y) = (a + bx) f_X(x)$ 에서

$$\sum_x \sum_y x y f(x,y) = \sum_x (ax + bx^2) f_X(x)$$

$$E(XY) = aE(X) + bE(X^2)$$

* $E(XY) = \sigma_{XY} + \mu_X \mu_Y$, $\sigma_{XY} = \rho \sigma_X \sigma_Y$, $E(X^2) - \mu_X^2 = \sigma_X^2$ 이므로
 $\mu_X \mu_Y + \rho \sigma_X \sigma_Y = a\mu_X + b(\mu_X^2 + \sigma_X^2)$ (2)

(1)과 (2):

$$\mu_Y = a + b\mu_X$$

$$\mu_X \mu_Y + \rho \sigma_X \sigma_Y = a\mu_X + b(\mu_X^2 + \sigma_X^2)$$

연립방정식의 해는 $a = \mu_Y - \rho \frac{\sigma_Y}{\sigma_X} \mu_X$, $b = \rho \frac{\sigma_Y}{\sigma_X}$

그러므로 $E(Y|x) = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X)$

If $p_1 = p_2 = 1$, then (5.18) reduces to

$$x_2|x_1 \sim \mathcal{N}\left(\mu_2 + \frac{\sigma_{12}}{\sigma_{11}}(x_1 - \mu_1), \sigma_{22} - \frac{\sigma_{12}^2}{\sigma_{11}}\right)$$

$$\begin{aligned}\sigma_{Y|x}^2 &= \int_{-\infty}^{\infty} (y - E(Y|x))^2 f(y|x) dy \\&= \int_{-\infty}^{\infty} \left(y - \mu_Y - \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X)\right)^2 f(y|x) dy \\ \int_{-\infty}^{\infty} \sigma_{Y|x}^2 f_X(x) dx &= \int_{-\infty}^{\infty} \left(\int_{-\infty}^{\infty} \left(y - \mu_Y - \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X)\right)^2 f(y|x) dy \right) f_X(x) dx \\ \sigma_{Y|x}^2 &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \left(y - \mu_Y - \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X)\right)^2 f(y|x) f_X(x) dy dx \quad (\text{분산은 상수}) \\&= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} \left(y - \mu_Y - \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X)\right)^2 f(x, y) dy dx \\&= E\left((Y - \mu_Y)^2 - 2\rho \frac{\sigma_Y}{\sigma_X} (X - \mu_X)(Y - \mu_Y) + \rho^2 \frac{\sigma_Y^2}{\sigma_X^2} (X - \mu_X)^2\right) \\&= \sigma_Y^2 - 2\rho \frac{\sigma_Y}{\sigma_X} \sigma_{XY} + \rho^2 \frac{\sigma_Y^2}{\sigma_X^2} \sigma_X^2 \\&= \sigma_Y^2 - 2\rho \frac{\sigma_Y}{\sigma_X} \rho \sigma_X \sigma_Y + \rho^2 \frac{\sigma_Y^2}{\sigma_X^2} \sigma_X^2 \\&= \sigma_Y^2 - 2\rho^2 \sigma_Y^2 + \rho^2 \sigma_Y^2 = \sigma_Y^2 (1 - \rho^2)\end{aligned}$$

* $p = 2$ 인 경우 이변량 정규분포

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix}, \quad |\Sigma| = \sigma_{11}\sigma_{22} - \sigma_{12}^2, \quad \Sigma^{-1} = \frac{1}{\sigma_{11}\sigma_{22} - \sigma_{12}^2} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{12} & \sigma_{11} \end{bmatrix}, \quad \rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}\sigma_{22}}},$$

$\sigma_{12} = \rho_{12} \sqrt{\sigma_{11}\sigma_{22}}$]므로,

$$|\Sigma| = \sigma_{11}\sigma_{22} - \sigma_{12}^2 = \sigma_{11}\sigma_{22} - \rho_{12}^2\sigma_{11}\sigma_{22} = \sigma_{11}\sigma_{22}(1 - \rho_{12}^2) = \sigma_1^2\sigma_2^2(1 - \rho^2)$$

$$\begin{aligned} (x - \mu)^t \Sigma^{-1} (x - \mu) &= \frac{1}{\sigma_1^2\sigma_2^2(1 - \rho^2)} [x_1 - \mu_1 \ x_2 - \mu_2] \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{12} & \sigma_{11} \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \\ &= \frac{1}{\sigma_1^2\sigma_2^2(1 - \rho^2)} [(x_1 - \mu_1)\sigma_{22} - (x_2 - \mu_2)\sigma_{12} \quad - (x_1 - \mu_1)\sigma_{12} + (x_2 - \mu_2)\sigma_{11}] \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \\ &= \frac{1}{\sigma_1^2\sigma_2^2(1 - \rho^2)} [(x_1 - \mu_1)^2\sigma_{22} - (x_1 - \mu_1)(x_2 - \mu_2)\sigma_{12} - (x_1 - \mu_1)(x_2 - \mu_2)\sigma_{12} + (x_2 - \mu_2)^2\sigma_{11}] \\ &= \frac{1}{\sigma_1^2\sigma_2^2(1 - \rho^2)} ((x_1 - \mu_1)^2\sigma_2^2 - 2(x_1 - \mu_1)(x_2 - \mu_2)\sigma_{12} + (x_2 - \mu_2)^2\sigma_1^2) \\ &= \frac{1}{(1 - \rho^2)} \left(\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho\sigma_1\sigma_2 \frac{1}{\sigma_1^2\sigma_2^2} (x_1 - \mu_1)(x_2 - \mu_2) + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right) \\ &= \frac{1}{(1 - \rho^2)} \left(\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)}{\sigma_1} \frac{(x_2 - \mu_2)}{\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right) \end{aligned}$$

그러므로 $f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2(1 - \rho^2)} e^{-\frac{Q}{2}},$

$$Q = \frac{1}{(1 - \rho^2)} \left(\frac{(x_1 - \mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1 - \mu_1)}{\sigma_1} \frac{(x_2 - \mu_2)}{\sigma_2} + \frac{(x_2 - \mu_2)^2}{\sigma_2^2} \right)$$

5.3 다모수 패밀리의 피셔 정보 경계

5.4 다항분포

$$x \sim \text{Mult}_L(n, \pi)$$



$$f_{\pi}(x) = \frac{n!}{x_1!x_2!\dots x_L!} \prod_{l=1}^L \pi_l^{x_l}$$

관측치가 오직 유한한 개수의 이산 값

	success	failure
new	1 9	2 12
old	3 7	4 17

$$L = 4$$

$$\begin{aligned} x &= (9, 12, 7, 17)' \\ x_l &= \#\{\text{cases having outcome } l\} \end{aligned}$$



$$e_l = (0, 0, \dots, 0, 1, 0, \dots, 0)'$$

이항분포: 성공확률이 p , 실패확률이 $q = 1 - p$ 인 베르누이 시행의 n 회의 독립시행에서 성공횟수를 나타내는 이항확률변수 X 의 확률분포는

$$b(x; n, p) = \binom{n}{x} p^x q^{n-x}, \quad x = 0, 1, 2, \dots, n \text{ 으로 주어진다.}$$

다항분포 : 각 시행에서 p_1, p_2, \dots, p_k 의 확률로 E_1, E_2, \dots, E_k 중 어느 하나가 발생할 경우, n 번의 독립시행에서 각각 E_1, E_2, \dots, E_k 의 발생횟수를 나타내는 확률변수 X_1, X_2, \dots, X_k 의 확률

$$\text{분포는 } f(x_1, x_2, \dots, x_k; p_1, p_2, \dots, p_k, n) = \binom{n}{x_1, x_2, \dots, x_k} p_1^{x_1} p_2^{x_2} \cdots p_k^{x_k}$$

$$\left(\sum_{i=1}^k x_i = n, \quad \sum_{i=1}^k p_i = 1 \right)$$

5.5 지수 패밀리

$$\frac{f_\mu(x)}{f_{\mu_0}(x)} = e^{-(\mu-\mu_0)} \left(\frac{\mu}{\mu_0} \right)^x \quad \longrightarrow \quad f_\mu(x) = e^{\alpha x - \psi(\alpha)} f_{\mu_0}(x)$$

$$\alpha = \log\{\mu/\mu_0\}$$

$$\psi(\alpha) = \mu_0(e^\alpha - 1)$$

$$\tilde{f}_\mu(x) = e^{\alpha x} f_{\mu_0}(x) \qquad e^{\psi(\alpha)} = \sum_0^\infty e^{\alpha x} f_{\mu_0}(x)$$




Figure 5.6 Poisson densities for $\mu = 3, 6, 9, 12, 15, 18$; heavy green curve with dots for $\mu = 12$.

$$\begin{aligned}
f_{\alpha}(x) &= \prod_{i=1}^n e^{\alpha' y_i - \psi(\alpha)} f_0(x_i) \\
&= e^{n(\alpha' \bar{y} - \psi(\alpha))} f_0(x),
\end{aligned}$$

왜 다른 변환 형식을 고려하지 않고 지수적 기울임에 관심을 두는 것일까? 그 대답은 반복된 표본추출과 관련 있다.
 n 이 얼마나 커지는 모든 추론 정보를 p 차원 통계량 y (bar)에 압축할 수 있다. → 수학적 용이성